UNIVERSIDAD POLITÉCNICA DE ATLAUTLA
Ing. en Tecnologías de la Información e Innovación Digital

ACTIVIDAD PARCIAL 2

Fundamentos de Inteligencia Artificial

SECCIÓN 1 · 1.7 APLICACIONES Y CASOS DE ESTUDIO DE IA

Aplicaciones y casos de estudio de IA

Alumno	Erandy Naomy Rosas Toriz
Grupo	171 · Cuatrimestre 7
Asignatura	Fundamentos de Inteligencia Artificial
Docente	Mtro. Javier García Lara
Periodo	12 al 26 de Octubre de 2026
Fecha de entrega	18 de octubre de 2026
Modalidad	Individual
Repositorio	FIA_G171_Rosas/S1

1. Planteamiento del problema

La inteligencia artificial (IA) se ha vuelto una herramienta de uso cotidiano, pero no toda aplicación publicitada demuestra resultados verificables. La actividad pide seleccionar **tres casos reales** de aplicación de IA en distintos sectores y, para cada uno, describir el problema que resuelve, las técnicas empleadas y su **impacto medible con fuente verificable**, para luego compararlos con una infografía y una tabla de criterios (rama de IA, técnica, sector, KPI, país).

Pregunta guía: ¿qué tipo de problema resuelve cada caso, con qué familia de técnicas y qué evidencia cuantitativa existe de que funciona?

Criterios de selección

- **Sectores distintos** (salud, logística/industria y movilidad) para contrastar tipos de problema.
- **Ramas de IA distintas**: aprendizaje profundo en visión, optimización/búsqueda heurística y aprendizaje automático en sistemas autónomos (ligadas a los temas del curso: búsqueda y optimización).
- **Cifras públicas y citables** de una fuente primaria o de una publicación que las reporte directamente.

Metodología

Se buscó en la web el 9 de octubre de 2026 y se leyeron las páginas fuente para extraer las cifras. Cada dato numérico del informe indica su fuente; cuando el dato proviene de una nota que resume un estudio, se señala. Los indicadores de cada caso son propios y **no son comparables entre sí** (p. ej., sensibilidad clínica frente a galones de combustible); la comparación es de tipo de problema, técnica y solidez de la evidencia.

2. Casos de estudio

Caso 1 · IDx-DR: detección autónoma de retinopatía diabética (salud, EE. UU.)

Descripción. IDx-DR es un software que analiza fotografías del fondo de ojo y decide, sin que un especialista las interprete, si el paciente tiene retinopatía diabética mayor que leve y debe ser referido a un oftalmólogo. En abril de 2018 recibió autorización de la FDA de EE. UU. (News-Medical, 2018; Abràmoff et al., 2018), y se considera uno de los primeros sistemas de IA autorizados para emitir un diagnóstico de forma autónoma.

Problema resuelto. La retinopatía diabética es una causa de ceguera prevenible si se detecta a tiempo, pero muchas personas con diabetes no acuden a un oftalmólogo. Llevar el tamizaje a consultorios de atención primaria exige un diagnóstico confiable sin especialista presente.

Técnicas. Aprendizaje automático supervisado con aprendizaje profundo (redes neuronales convolucionales) sobre imágenes de fondo de ojo: clasificación binaria de la imagen en «referir» o «repetir examen en 12 meses», más un control de calidad que decide si la imagen es analizable.

Impacto medible. En el ensayo clínico pivotal participaron 900 personas en 10 consultorios de atención primaria. El sistema obtuvo una sensibilidad cercana a 87 %, una especificidad cercana a 90 % y pudo analizar el 96 % de los casos (imageabilidad), frente a un estándar de referencia de lectores expertos (News-Medical, 2018). El estudio fue publicado en *npj Digital Medicine* (Abràmoff et al., 2018).

KPI principal: sensibilidad / especificidad frente al estándar de referencia. **Consideraciones:** un 13 % de falsos negativos en pacientes con la enfermedad es un riesgo clínico que exige seguimiento, y el

desempeño depende de la calidad de la imagen y de la población evaluada.

Caso 2 · UPS ORION: optimización de rutas de reparto (logística, EE. UU.)

Descripción. ORION (On-Road Integrated Optimization and Navigation) es el sistema con el que UPS calcula cada mañana la ruta de cada conductor. Combina mapas, telemática y un algoritmo de optimización propietario que, según UPS (citada por Henschen, 2013), evalúa más de 200,000 formas de recorrer una sola ruta.

Problema resuelto. Ordenar decenas de paradas por conductor minimizando millas, tiempo y combustible, respetando reglas de negocio (clientes prioritarios, ventanas de entrega). Es una variante del problema del viajante (TSP) y del ruteo de vehículos: un problema de **optimización combinatoria**, el mismo tipo de problema que se modela en las secciones 2 y 3 de esta actividad.

Técnicas. Optimización matemática y heurística sobre datos geoespaciales, con refinamiento de mapas y comunicación en tiempo real con el conductor. UPS describe el algoritmo como propietario; por la naturaleza del problema (NP-difícil) se infiere el uso de heurísticas, ya que un método exacto no escala.

Impacto medible. Henschen (2013) reporta cerca de 1.5 millones de galones de combustible y alrededor de 14,000 toneladas métricas de CO_2 evitadas, y estima que eliminar una milla diaria por conductor ahorraría 50 millones de dólares al año. El despliegue pasó de un centro de distribución en 2009 (beta) a nueve en 2010, con 82 centros planeados para finales de 2013 y las 55,000 rutas objetivo para 2017.

KPI principal: galones de combustible y millas ahorradas. **Consideraciones:** las cifras son de 2013 y provienen de declaraciones de la empresa en una nota periodística; la propia nota no revela las millas ahorradas, así que debe tratarse como evidencia de nivel medio.

Caso 3 · Waymo: conducción autónoma (movilidad, EE. UU.)

Descripción. Waymo opera vehículos que circulan sin conductor humano a bordo («rider-only») en Phoenix, San Francisco, Los Ángeles y Austin. La empresa publica periódicamente un análisis de seguridad que compara sus choques con los de conductores humanos en las mismas zonas.

Problema resuelto. Reducir los choques con lesiones, causados en su mayoría por error humano, automatizando percepción del entorno, predicción del comportamiento de otros usuarios y planeación de trayectorias.

Técnicas. Aprendizaje automático aplicado a datos de sensores (cámaras, lidar y radar) para percepción y predicción, y algoritmos de búsqueda y planeación para decidir la trayectoria. (Descripción general de la familia de técnicas; Waymo no publica en esa página el detalle de sus modelos.)

Impacto medible. Con 271.3 millones de millas sin conductor hasta junio de 2026, Waymo (2026) reporta frente al benchmark humano: 95 % menos choques con lesiones graves o peores, 82 % menos choques con lesión, 82 % menos con despliegue de airbag y 93 % menos choques con peatón lesionado. El benchmark usa tasas de conductores humanos en las mismas ciudades, solo calles urbanas (sin autopistas), e incluye un ajuste de 32 % por subregistro de lesiones.

KPI principal: reducción porcentual de choques por millas recorridas. **Consideraciones:** es un análisis publicado por la propia empresa y la comparación es modelada, no un experimento controlado (EVwire, 2026, lo describe así); el resultado es válido para las ciudades y condiciones donde opera y no se extrapola a cualquier carretera o clima.

3. Infografía comparativa

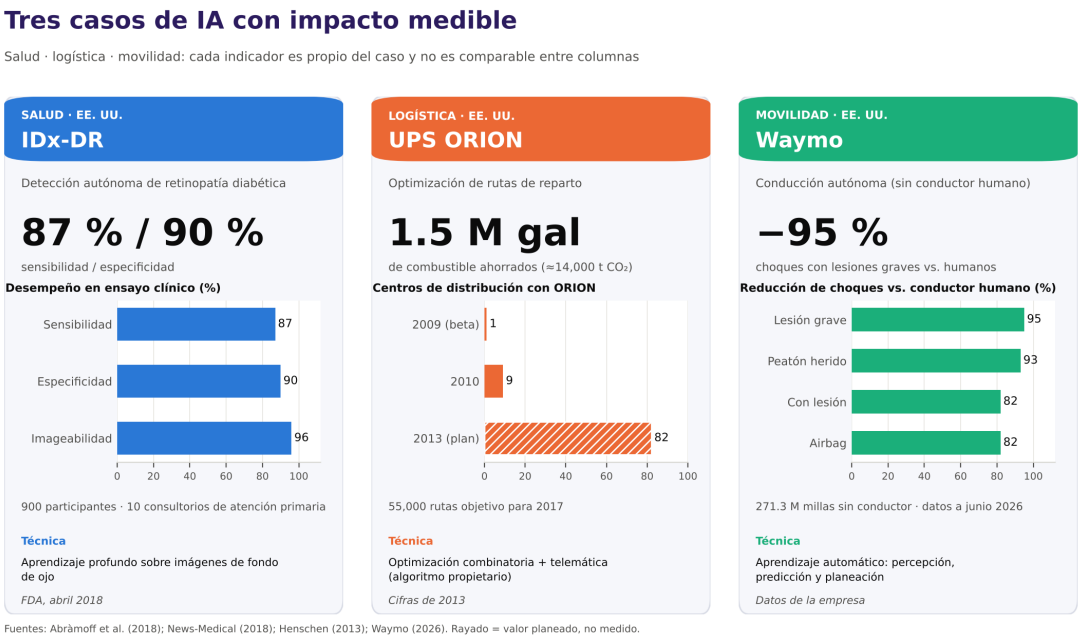


Figura 1. *Infografía de los tres casos. Elaboración propia con datos de Abràmoff et al. (2018), News-Medical (2018), Henschen (2013) y Waymo (2026).*

4. Tabla comparativa por criterios

Criterio	IDx-DR	UPS ORION	Waymo
Sector	Salud	Logística / industria	Movilidad / transporte
País	EE. UU.	EE. UU. (operación global de UPS)	EE. UU.
Rama de IA	Aprendizaje automático: visión por computadora	Optimización y búsqueda heurística	Aprendizaje automático + percepción + planeación (sistemas autónomos)
Técnica	Redes neuronales convolucionales (aprendizaje profundo) con aprendizaje supervisado	Optimización combinatoria (tipo TSP / ruteo de vehículos) y telemática	Modelos de percepción y predicción con sensores; planeación de trayectorias
Problema	Tamizaje de retinopatía diabética sin especialista presente	Ordenar paradas de reparto para ahorrar millas y combustible	Reducir choques con lesiones sin conductor humano
KPI	Sensibilidad ≈87 %, especificidad ≈90 %, imageabilidad 96 %	≈1.5 M de galones y ≈14,000 t de CO_2 ahorrados (2013)	−95 % choques con lesiones graves; −82 % con lesión (271.3 M millas)
Tipo de evidencia	Ensayo clínico prospectivo, revista científica y aprobación regulatoria	Declaraciones de la empresa en nota periodística (2013)	Análisis de la empresa vs. benchmark modelado
Fuente principal	Abràmoff et al. (2018); News-Medical (2018)	Henschen (2013)	Waymo (2026)

Tabla 1. *Criterios comparativos de los tres casos.*

5. Análisis y conclusiones reflexivas

- **La IA resuelve problemas de naturaleza distinta.** IDx-DR *percibe y clasifica* (aprendizaje a partir de datos), ORION *optimiza* (búsqueda en un espacio enorme de rutas) y Waymo combina ambas: percibe, predice y planea. Por eso el curso enseña tanto aprendizaje como búsqueda.
- **La calidad de la evidencia varía.** Solo IDx-DR cuenta con ensayo clínico y aprobación regulatoria; los otros dos casos descansan en datos reportados por las propias empresas, lo que obliga a leerlos con cautela.
- **Cifras altas no implican ausencia de riesgo.** Con 87 % de sensibilidad, de cada 100 personas enfermas unas 13 no serían referidas; el valor de la IA depende de dónde y cómo se usa. En movilidad, la reducción de choques se mide solo en ciudades y condiciones específicas.
- **Dimensión ética y de gobernanza.** En salud importan la responsabilidad ante errores y el sesgo por población de entrenamiento; en conducción autónoma, la transparencia de los datos de seguridad y su auditoría independiente; en logística, el efecto sobre la carga de trabajo de los conductores.
- **Conexión con la actividad.** El caso de UPS es, en esencia, el problema que se modela (sección 2) y se optimiza con Hill Climbing y Simulated Annealing (sección 3): rutas mínimas sobre grafos.

6. Declaración de uso de inteligencia artificial

Herramienta	Claude (Anthropic), modelo Claude Sonnet 5.5, con búsqueda web y ejecución de código Python.
Prompt (resumen)	Se entregó la hoja de la Actividad Parcial 2 y se pidió realizar las secciones 1 a 4 «muy bien». Para esta sección: investigar tres casos reales, extraer cifras con fuente, elaborar infografía, tabla y conclusiones.
Uso	Búsqueda y lectura de las fuentes, redacción del borrador, programación de la infografía (matplotlib) y maquetación del PDF (reportlab).
Verificación	Las cifras de Waymo, UPS e IDx-DR se leyeron en las páginas citadas el 9/10/2026. Las de IDx-DR provienen de News-Medical, un resumen del ensayo, y deben contrastarse con la tabla de resultados del artículo original (Abràmoff et al., 2018) antes de entregar. Se revisaron redacción, citas APA e infografía.

Referencias (APA 7.ª ed.)

Abràmoff, M. D., Lavin, P. T., Birch, M., Shah, N., & Folk, J. C. (2018). Pivotal trial of an autonomous AI-based diagnostic system for detection of diabetic retinopathy in primary care offices. *npj Digital Medicine, 1*, Artículo 39. https://doi.org/10.1038/s41746-018-0040-6

EVwire. (2026, 24 de junio). *Waymo safety update: 220 million miles, 94 percent fewer crashes*. https://evwire.com/p/waymo-safety-update-220-million-miles-94-percent-fewer-crashes

Henschen, D. (2013, 4 de noviembre). UPS nets huge fuel savings with analytics. *InformationWeek*. https://www.informationweek.com/data-management/ups-nets-huge-fuel-savings-with-analytics

News-Medical. (2018, 28 de agosto). *New system that uses AI accurately detects patients with diabetic retinopathy*. https://www.news-medical.net/news/20180828/New-system-that-uses-AI-accurately-detects-patients-with-diabetic-retinopathy.aspx

Russell, S., & Norvig, P. (2020). *Inteligencia Artificial: Un enfoque moderno* (4.ª ed.). Pearson.

Waymo. (2026). *Safety impact*. Recuperado el 9 de octubre de 2026, de https://waymo.com/safety/impact/

Anexo A. Código Python de la infografía

Repositorio: FIA_G171_Rosas/S1_casos_ia · archivo **s1_infografia.py**

```
"""S1 · Infografía comparativa de 3 casos de IA (salud, industria/logística, movilidad).

Todas las cifras provienen de las fuentes citadas en el informe (consultadas el 9-oct-2026):
  · IDx-DR  -> ensayo pivotal (Abràmoff et al., 2018) vía News-Medical (2018)
  · UPS ORION -> Henschen (2013), InformationWeek
  · Waymo -> Waymo (2026), página "Safety Impact" (datos a junio de 2026)

Ejecutar:  python s1_infografia.py      (genera figuras/infografia_casos.png)
"""
import os
import sys
import textwrap

sys.path.insert(0, os.path.join(os.path.dirname(__file__), "..", "common"))
import estilo  # noqa: E402

estilo.aplicar()
import matplotlib.pyplot as plt  # noqa: E402
from matplotlib.patches import FancyBboxPatch  # noqa: E402

AQUI = os.path.dirname(os.path.abspath(__file__))
FIG = os.path.join(AQUI, "figuras")
os.makedirs(FIG, exist_ok=True)

# ---- datos de cada caso (tomados de las fuentes)
CASOS = [
    {"sector": "SALUD · EE. UU.", "nombre": "IDx-DR", "sub": "Detección autónoma de retinopatía diabética",
     "color": estilo.AZUL, "grande": "87 % / 90 %", "grande_et": "sensibilidad / especificidad",
     "barras": [("Sensibilidad", 87), ("Especificidad", 90), ("Imageabilidad", 96)],
     "tit_graf": "Desempeño en ensayo clínico (%)", "n": "900 participantes · 10 consultorios de atención primaria",
     "tecnica": "Aprendizaje profundo sobre imágenes de fondo de ojo", "anio": "FDA, abril 2018"},
    {"sector": "LOGÍSTICA · EE. UU.", "nombre": "UPS ORION", "sub": "Optimización de rutas de reparto",
     "color": estilo.NARANJA, "grande": "1.5 M gal", "grande_et": "de combustible ahorrados (≈14,000 t CO₂)",
     "barras": [("2009 (beta)", 1), ("2010", 9), ("2013 (plan)", 82)],
     "tit_graf": "Centros de distribución con ORION", "n": "55,000 rutas objetivo para 2017",
     "tecnica": "Optimización combinatoria + telemática (algoritmo propietario)", "anio": "Cifras de 2013"},
    {"sector": "MOVILIDAD · EE. UU.", "nombre": "Waymo", "sub": "Conducción autónoma (sin conductor humano)",
     "color": estilo.AQUA, "grande": "−95 %", "grande_et": "choques con lesiones graves vs. humanos",
     "barras": [("Lesión grave", 95), ("Peatón herido", 93), ("Con lesión", 82), ("Airbag", 82)],
     "tit_graf": "Reducción de choques vs. conductor humano (%)",
     "n": "271.3 M millas sin conductor · datos a junio 2026",
     "tecnica": "Aprendizaje automático: percepción, predicción y planeación", "anio": "Datos de la empresa"},
]


def tarjeta(fig, i, caso):
    ancho, gap, x0 = 0.30, 0.025, 0.04
    x = x0 + i * (ancho + gap)
    # fondo de tarjeta
    fondo = fig.add_axes([x, 0.04, ancho, 0.80]); fondo.axis("off")
    fondo.add_patch(FancyBboxPatch((0, 0), 1, 1, boxstyle="round,pad=0,rounding_size=0.03", fc="#F6F7FB",
                                   ec="#D9DCE6", lw=1, transform=fondo.transAxes))
    # encabezado
    enc = fig.add_axes([x, 0.74, ancho, 0.10]); enc.axis("off")
    enc.add_patch(FancyBboxPatch((0, 0), 1, 1, boxstyle="round,pad=0,rounding_size=0.12", fc=caso["color"],
                                 ec="none", transform=enc.transAxes))
    enc.text(0.05, 0.70, caso["sector"], color="white", fontsize=8, fontweight="bold", va="center")
    enc.text(0.05, 0.30, caso["nombre"], color="white", fontsize=15, fontweight="bold", va="center")
    # subtítulo, cifra grande
    fig.text(x + 0.015, 0.705, caso["sub"], fontsize=8.2, color=estilo.TINTA2, va="center")
    fig.text(x + 0.015, 0.625, caso["grande"], fontsize=26, fontweight="bold", color=estilo.TINTA, va="center")
    fig.text(x + 0.015, 0.575, caso["grande_et"], fontsize=8, color=estilo.TINTA2, va="center")
    # mini gráfica de barras horizontales
    ax = fig.add_axes([x + 0.10, 0.275, ancho - 0.12, 0.25])
    nombres = [b[0] for b in caso["barras"]][::-1]
    valores = [b[1] for b in caso["barras"]][::-1]
    barras = ax.barh(nombres, valores, color=caso["color"], height=0.58)
    if caso["nombre"] == "UPS ORION":
        barras[0].set_hatch("////"); barras[0].set_edgecolor("white")        # 2013 = plan, no medición
        ax.set_xlim(0, 100)
    else:
        ax.set_xlim(0, 112)
    for b, v in zip(barras, valores):
        ax.text(v + 1.5, b.get_y() + b.get_height() / 2, f"{v}", va="center", fontsize=8, color=estilo.TINTA)
    ax.set_title(caso["tit_graf"], fontsize=8, fontweight="bold", loc="left", x=-0.55)
```

```
    ax.tick_params(axis="y", labelsize=8, length=0); ax.tick_params(axis="x", labelsize=7)
    ax.spines["left"].set_visible(False); ax.grid(axis="y", visible=False)
    # pie de tarjeta
    fig.text(x + 0.015, 0.205, caso["n"], fontsize=7.6, color=estilo.TINTA2, va="center")
    fig.text(x + 0.015, 0.152, "Técnica", fontsize=7.6, fontweight="bold", color=caso["color"], va="center")
    fig.text(x + 0.015, 0.108, "\n".join(textwrap.wrap(caso["tecnica"], 44)), fontsize=7.6, color=estilo.TINTA,
             va="center", linespacing=1.35)
    fig.text(x + 0.015, 0.060, caso["anio"], fontsize=7.4, style="italic", color=estilo.TINTA2, va="center")


def main():
    fig = plt.figure(figsize=(11, 6.3))
    fig.text(0.04, 0.945, "Tres casos de IA con impacto medible", fontsize=17, fontweight="bold", color=estilo.INDIGO)
    fig.text(0.04, 0.895, "Salud · logística · movilidad: cada indicador es propio del caso y no es comparable "
             "entre columnas", fontsize=9, color=estilo.TINTA2)
    for i, c in enumerate(CASOS):
        tarjeta(fig, i, c)
    fig.text(0.04, 0.012, "Fuentes: Abràmoff et al. (2018); News-Medical (2018); Henschen (2013); Waymo (2026). "
             "Rayado = valor planeado, no medido.", fontsize=7, color=estilo.TINTA2)
    fig.savefig(os.path.join(FIG, "infografia_casos.png"))
    plt.close(fig)


if __name__ == "__main__":
    main()
```